

太赫兹探头油液识别训练报告

基于训练数据的稳健特征提取、模型比较、距离鲁棒性验证与测试集预测

技术摘要

- 训练数据包含 48 个采集文件、6489 个记录块；测试数据包含 6 个文件、39 个记录块。每个记录块包含 Pos、Dis、data 与 CFAR 阈值曲线。
- 最终选择 logistic_l2，使用 173 个稳定工程特征，部署阈值为 0.42。最终特征集中没有直接使用原始 Pos/Dis 作为判别特征，避免模型只学到采集位置差异。
- 文件分组交叉验证的文件级 AUC 为 0.998，文件级平衡准确率为 97.9%；48 个训练文件的折外预测中，1 个无油文件误判为有油，0 个有油文件漏判。
- 按距离留一验证的文件级平衡准确率均值为 95.8%，最低为 87.5%，说明模型不是单纯依赖某个固定距离或某个峰值。
- 测试集未提供真实标签，因此不能计算测试准确率；本报告仅给出严格隔离后的测试预测。ceshi_2 的概率为 56.4%，接近阈值，建议后续作为重点复核样本。

测试集预测结论

测试文件	预测	有油概率	阳性块比例	记录块数	Dis(mm)
ceshi_1.DAT	无油	4.3%	0.0%	6	150
ceshi_2.DAT	有油	56.4%	71.4%	7	150
ceshi_3.DAT	无油	17.5%	20.0%	5	150
ceshi_4.DAT	有油	100.0%	100.0%	6	150,263
ceshi_5.DAT	有油	99.9%	100.0%	6	150,188
ceshi_6.DAT	有油	100.0%	100.0%	9	150,188,263




图 1. 测试文件有油概率；虚线为部署阈值。

数据隔离与样本组织

训练数据与测试数据位于不同目录，脚本先解析训练目录完成模型选择、交叉验证、阈值选择和最终拟合；测试目录只在这些步骤完成后读取并预测。验证时按源文件分组，同一采集文件内的多个记录块不会同时进入训练折和验证折，避免把同一次采集的重复结构泄漏到验证结果中。

- 训练标签来源：训练数据/有油 与 训练数据/无油 两个目录。
- 距离层级：0cm、10cm、20cm、30cm、40cm、50cm；每个类别每个距离 4 个训练文件。
- 基本解析单位：一个 DAT 内的每个 Pos/Dis/data-cfar 块作为记录块，文件级预测通过记录块概率均值聚合。
- 测试集标签状态：测试文件夹未包含真实标签或标签目录，因此未参与任何训练、特征选择、阈值选择或评价。

Example data and CFAR traces

Features use peak structure, residual area, windows, spectra, and robust normalized amplitudes.




图 2. 有油/无油示例记录块的 data 与 CFAR 曲线。

特征工程

特征组	数量	说明
稳健幅值与形态	43	中位数/MAD 归一化、分位数、RMS、峰度、偏度、总变差、形状熵
CFAR 阈值关系	39	data-cfar 残差、超过阈值比例、超过阈值面积、最大阈值裕量、data/CFA R 比值
多峰结构	46	峰数量、峰显著性、峰宽、Top1-Top5 峰位置/幅值/间距、主次峰比例
多路径窗口	34	将 220 点记录分为 5 个相对距离窗口，提取窗口能量、残差、峰数和前后窗比例
频谱结构	7	低/中/高频能量占比、谱质心、谱带宽、谱熵
距离归一化	3	相对峰位置、稳健 z-score、能量占比，以及按距离平方校正的幅值/CFA R 裕量

这些特征覆盖界面反射变化、回波幅值变化、多峰结构变化、CFAR 阈值与目标峰关系、探头到容器/液面/背面等多路径回波变化，以及距离变化下的归一化表达。最终模型没有直接使用原始位置字段，但保留了物理上更合理的相对位置和距离校正幅值。

Top 特征	模型重要性
win4_z_max	1.385
peak_top2_prominence	1.223
cfar_corr_data	1.209
win4_peak_count	1.149
distnorm_raw_rms_times_r2	1.144
spec_energy_0.05_0.12	1.050
spec_energy_0.25_0.50	1.014
peak_top5_idx_rel	1.006
peak_top1_top2_gap_rel	0.957
win2_peak_count	0.955




图 3. 最终模型中权重最高的工程特征。

模型与验证方法

候选模型覆盖线性可解释模型和非线性树模型：L2 逻辑回归、ExtraTrees、随机森林、直方梯度提升。所有模型都在训练集内完成比较；缺失值通过中位数填充，逻辑回归使用标准化。阈值使用文件级折外预测选择，最终阈值为 0.42。

模型	文件级平衡准确率	文件级 AUC	块级平衡准确率	块级 AUC
logistic_l2	97.9%	0.998	95.1%	0.971
extra_trees	91.7%	0.979	90.8%	0.970
random_forest	91.7%	0.972	89.5%	0.960
hist_gbdt	89.6%	0.957	89.8%	0.944




图 4. 稳定特征集下的文件分组交叉验证结果。

距离鲁棒性

为了检验距离归一化是否有效，额外执行按距离留一验证：每次保留一个 nominal distance 作为验证距离，其余五个距离训练模型。该验证比随机块级划分更接近后续距离变化场景。

留出距离(cm)	文件级平衡准确率	文件级 AUC	块级 0.5 准确率	文件数
0	100.0%	1.000	89.5%	8
10	100.0%	1.000	100.0%	8
20	100.0%	1.000	97.1%	8
30	100.0%	1.000	97.1%	8
40	87.5%	1.000	81.5%	8
50	87.5%	1.000	91.8%	8




图 5. 按距离留一验证；40cm 与 50cm 相对更弱，但仍高于 87.5%。

折外误差与阈值

真实/预测	预测无油	预测有油
真实无油	23	1
真实有油	0	24

折外文件级混淆矩阵显示，当前阈值下有油样本无漏判；唯一错误是一个无油训练文件被判为有油。对于安全或防漏油场景，可以接受略偏保守的阈值；如果后续更关注误报率，可以在真实测试标签回填后重新调整阈值。

局限性与后续建议

- 当前测试集没有标签，无法报告真实测试准确率。拿到测试标签后，应只用 test_file_predictions.csv 做一次性评价，不要再用测试结果反向调模型。
- 训练集中每个距离每类只有 4 个文件，文件数仍偏少；虽然块数较多，但同一文件内块高度相关，因此报告优先使用文件级指标。
- ceshi_2 的预测概率接近阈值且块内一致性不高，建议复测或人工复核原始波形。

- 后续应加入真实容器、不同容器材料/壁厚、不同油量高度、重复装夹、温漂与探头姿态变化数据，继续做文件级或批次级分组验证。
- 若将模型部署到新采集批次，建议先用少量已知标签样本校准阈值，并监控 CFAR 残差、窗口能量和多峰间距的分布漂移。

可复现产物

产物	路径
训练脚本	scripts\train_oil_classifier.py
报告脚本	scripts\build_word_report.py
最终模型	outputs\oil_classifier_model.joblib
测试文件级预测	outputs\test_file_predictions.csv
训练摘要	outputs\training_summary.json
本报告	outputs\太赫兹探头油液识别训练报告.docx

复现命令：python scripts/train_oil_classifier.py --data-root shuju --output-dir outputs；随后运行python scripts/build_word_report.py 生成本 Word 报告。